

Table des matières

Chapitre 1

Cadre général du projet

Introduction

Ce chapitre a pour objectif de présenter le cadre général dans lequel s'inscrit ce projet de fin d'études. Nous commençons par une présentation de l'organisme d'accueil, puis nous effectuons une étude de l'existant afin d'identifier les lacunes des solutions actuelles de surveillance des systèmes SAP. Nous détaillons ensuite la problématique retenue, avant de présenter la solution proposée et la méthodologie de développement adoptée.

1.1 Présentation de l'organisme d'accueil

1.1.1 AVAXIA GROUP

AVAXIA GROUP est une société de conseil en technologies de l'information à dimension internationale, fondée en 2006. Elle dispose d'une présence stratégique dans plusieurs régions, avec son siège social à Dubaï et des centres opérationnels en Tunisie, au Japon et au Canada. L'organisation est spécialisée dans les solutions technologiques d'entreprise, avec un accent particulier sur l'implémentation des systèmes ERP (*Enterprise Resource Planning*), l'intégration de systèmes et les services gérés pour les applications métiers critiques. Son expertise technique s'étend à l'écosystème SAP ainsi qu'à des plateformes complémentaires telles que Salesforce.



FIGURE 1.1 – Logo Avaxia Group

1.1.2 Philosophie et approche

Avaxia Group adopte une méthodologie résolument centrée sur le client dans son modèle de prestation de services, en privilégiant des partenariats collaboratifs plutôt que des relations purement transactionnelles.

1.1.3 Portefeuille de services

Avaxia met à disposition un portefeuille complet de services numériques et de conseil, avec une forte orientation vers les solutions d'entreprise, le support d'infrastructure et les technologies émergentes. Le groupe est structuré autour de deux départements spécialisés, chacun offrant des domaines de services distincts :

- **Consultance fonctionnelle** : Conception de solutions métier pour le déploiement de nouveaux modules SAP fonctionnels, analyse et optimisation des processus de bout en bout, ainsi que la gestion du déploiement fonctionnel et de la planification des tests.
- **Big Data** : Services incluant la gestion, la transformation, l'intégration, le stockage et l'analyse des données. Les compétences couvrent le développement de pipelines de données, les processus ETL et la gouvernance des données.
- **VR / AR** : Développement d'environnements VR interactifs permettant aux utilisateurs de naviguer, d'interagir avec des objets et de collaborer en temps réel. Les applications comprennent les systèmes de surveillance, les simulations, les programmes de formation et les visites virtuelles.

1.1.4 Structure organisationnelle

L'architecture organisationnelle d'Avaxia Group est conçue pour faciliter une expertise spécialisée tout en maintenant une collaboration transversale. La structure du groupe s'articule autour de trois niveaux :

- **Organisation divisionnelle** : Assure les responsabilités de chaque département en fonction de son rôle, en gérant le développement commercial et les décisions stratégiques.
- **Organisation opérationnelle** : Se concentre sur les défis techniques et les expertises qui pilotent les projets et services (planification, exécution, livraison et support). Elle permet également de suivre, évaluer et optimiser les opérations de projets.
- **Structure corporative** : Supporte le front office en représentant les opérations internes (Finance, RH, Formation, Marketing, Qualité de service, Informatique), afin d'assurer la continuité de l'activité dans son ensemble.

Ce projet se déroule au sein de l'équipe Quadient, rattachée au département *SAP Infrastructure and BASIS* du bureau tunisien d'Avaxia Group. Les responsabilités de cette équipe englobent la surveillance et le support des systèmes SAP critiques auprès de plusieurs clients, ce qui en fait un environnement idéal pour développer et valider un système avancé de détection d'anomalies basé sur la technologie RAG.

1.2 Étude de l'existant

Dans le cadre du développement d'un système intelligent de surveillance des systèmes SAP au sein d'Avaxia Group, une étude de l'existant a été réalisée afin de comprendre les processus actuels mis en œuvre par l'équipe BASIS.

Rôle du consultant SAP BASIS

Le consultant SAP BASIS est responsable de l'administration technique des systèmes SAP. Ses missions principales incluent la surveillance des systèmes, la gestion des performances, le traitement des incidents techniques ainsi que la maintenance quotidienne des environnements SAP.

Dans le cadre de la surveillance, le consultant BASIS vérifie régulièrement l'état global du système à travers différentes transactions SAP. Il analyse les jobs en arrière-plan, les erreurs système, les impressions en attente ainsi que l'activité des processus. Ces actions permettent d'assurer le bon fonctionnement des systèmes et d'identifier les anomalies éventuelles.

Surveillance des systèmes SAP

La surveillance quotidienne des systèmes SAP repose sur l'utilisation de plusieurs codes de transaction (T-codes), chacun fournissant des informations spécifiques :

- SM37 : permet de consulter les jobs en arrière-plan et leur état d'exécution.
- ST22 : permet d'analyser les dumps ABAP générés par les erreurs système.
- SP01 : permet de visualiser les spools d'impression.
- DB02 : fournit des informations sur l'état de la base de données.
- SM66 : permet de superviser les processus actifs du système.

Ces transactions sont utilisées de manière régulière par les consultants BASIS afin de collecter les informations nécessaires à la supervision des systèmes SAP.




FIGURE 1.2 – Processus de surveillance manuelle des systèmes SAP

Structure des données SAP

Les systèmes SAP génèrent quotidiennement un volume important de données sous forme de logs. Chaque transaction produit des informations selon une structure spécifique.

Par exemple :

- SM37 expose des champs tels que *Job_Name*, *Job_ID*, *Status*, *Start_Date* et *End_Date*.
- ST22 fournit des informations comme *Error_Name*, *Server*, *Date*, *Time*, *User* et *Client*.
- SP01 contient des données telles que *Spool_Number*, *Owner*, *Created_On* et *Status*.

Ces données sont utilisées par les consultants pour analyser l'état du système et suivre les différentes activités en cours.




FIGURE 1.3 – Surcharge et hétérogénéité des données issues des T-codes SAP

Gestion de la connaissance SAP

La connaissance SAP au sein de l'équipe est répartie entre plusieurs sources : le portail SAP Help, qui organise la documentation de manière hiérarchique sur des milliers de pages, des livres techniques au format PDF, des SAP Notes référencées par numéro, et l'expérience individuelle des consultants. Chaque consultant accède à ces sources de manière indépendante selon ses besoins, sans système centralisé de partage ou de capitalisation des connaissances.

1.2.1 Critique de l'existant

L'analyse de l'existant met en évidence plusieurs limites structurelles et fonctionnelles dans les processus actuels de surveillance et de gestion de la connaissance au sein de l'équipe BASIS.

Limites de la surveillance des systèmes SAP

Le processus actuel de surveillance repose principalement sur une approche manuelle, dans laquelle les consultants BASIS interrogent individuellement plusieurs transactions afin d'obtenir une vision de l'état du système. Cette approche induit une dépendance forte à l'intervention humaine et mobilise un effort opérationnel important, notamment dans des environnements multi-systèmes.

En outre, l'absence de consolidation des informations issues des différents T-codes ne permet pas d'obtenir une vue globale et cohérente du système. Les données étant consultées de manière isolée, la corrélation entre événements devient difficile, ce qui limite la capacité d'analyse transversale.

Par ailleurs, le mode de surveillance actuel repose sur des mécanismes de détection basés sur des seuils statiques. Ce type d'approche présente des limites importantes : d'une part, il peut générer un volume élevé d'alertes non pertinentes dans le cas de variations normales du système ; d'autre part, certaines anomalies progressives ou atypiques peuvent ne pas être détectées si elles ne dépassent pas les seuils définis.

Enfin, l'absence de mécanismes d'analyse prédictive ou de détection des tendances empêche toute anticipation des dégradations du système, limitant ainsi la surveillance à une logique essentiellement réactive.

Limites liées à la gestion des données

Les données générées par les systèmes SAP présentent une forte hétérogénéité en termes de structure et de format, chaque transaction produisant ses propres champs et indicateurs. Cette diversité complique leur exploitation et rend difficile toute forme de traitement unifié.

L'absence d'un mécanisme d'agrégation ou de normalisation des données limite la possibilité d'analyse globale et empêche la mise en place d'outils avancés d'analyse, notamment dans le cadre de la détection d'anomalies ou de corrélations complexes entre événements.

De plus, le volume important de données à analyser quotidiennement constitue une charge cognitive significative pour les consultants, ce qui peut impacter l'efficacité du processus de surveillance et la rapidité de prise de décision.

Limites de la gestion des connaissances SAP

La gestion des connaissances au sein de l'équipe repose sur un ensemble de sources hétérogènes et distribuées, incluant la documentation officielle, les SAP Notes et les ressources internes. Cette organisation ne repose sur aucun système unifié permettant une centralisation ou une structuration des informations.

La recherche d'information s'effectue généralement à partir de mots-clés, sans prise en compte du contexte sémantique ni des relations entre les documents. Cela peut entraîner des difficultés dans l'identification rapide des informations pertinentes.

Par ailleurs, les liens entre les différentes documentaires ne sont pas explicitement structurés, ce qui oblige les consultants à naviguer manuellement entre plusieurs sources. Cette situation peut allonger les délais de résolution des incidents.

Enfin, la dépendance à l'expertise individuelle constitue un facteur de fragilité

organisationnelle. L'absence de mécanismes de capitalisation et de partage structuré des connaissances peut entraîner une perte d'information critique en cas d'indisponibilité ou de départ de certains experts.

1.2.2 Solutions existantes et analyse concurrentielle

Plusieurs solutions dédiées ou adaptées à la surveillance des environnements SAP existent actuellement. Ces solutions se distinguent principalement par leur niveau d'intégration avec l'écosystème SAP, leurs capacités d'analyse ainsi que leur approche de la détection des anomalies.

Outils natifs SAP

Les outils natifs proposés par SAP constituent la première catégorie de solutions utilisées pour la supervision des systèmes. Parmi eux, SAP Solution Manager (SolMan) offre un ensemble de fonctionnalités intégrées permettant la surveillance technique, la gestion des incidents ainsi que le suivi des performances des systèmes SAP.

Cette solution présente l'avantage d'une intégration native avec les environnements SAP, permettant un accès direct aux données internes et aux transactions. Elle propose également des mécanismes de monitoring centralisé et des outils de diagnostic.

Cependant, ces outils restent principalement orientés vers une surveillance technique classique. Ils reposent en grande partie sur des règles et des seuils prédéfinis, et offrent des capacités limitées en matière d'analyse intelligente, notamment en ce qui concerne la détection proactive des anomalies ou l'interprétation contextuelle des événements.

Solutions SAP basées sur le Machine Learning

SAP propose également des solutions intégrant des capacités de Machine Learning, notamment à travers SAP Leonardo ML. Ces solutions permettent d'exploiter les données générées par les systèmes SAP afin d'identifier des patterns et de détecter certaines anomalies.

L'intégration native avec les systèmes ERP constitue un avantage majeur, facilitant l'accès aux données et leur traitement en temps réel. Ces outils permettent également d'introduire une dimension prédictive dans la surveillance des systèmes.

Néanmoins, ces solutions présentent certaines limites, notamment en termes de flexibilité et de personnalisation. Elles sont généralement dépendantes de l'écosystème SAP et souvent orientées vers des déploiements cloud, ce qui peut ne pas convenir à toutes les architectures existantes. De plus, leur coût peut représenter un frein pour certaines organisations.

Approches hybrides et pratiques courantes

En complément des outils existants, de nombreuses organisations adoptent des approches hybrides combinant les outils SAP avec des procédures manuelles réalisées par les consultants BASIS. Ces pratiques incluent l'utilisation des T-codes de surveillance ainsi que l'analyse directe des logs système.

Cette approche permet une certaine flexibilité et une adaptation aux besoins spécifiques de chaque environnement SAP. Elle repose toutefois fortement sur l'expertise humaine et nécessite une interprétation manuelle des informations collectées.

Synthèse comparative

TABLE 1.1 – Synthèse des solutions de surveillance SAP

Catégorie	Approche	Points forts	Limites
Outils natifs SAP (SolMan)	Surveillance basée sur T-codes et règles prédéfinies	Intégration native avec SAP Accès direct aux données système Supervision centralisée	Faible capacité d'analyse intelligente Basé sur des seuils statiques Peu flexible
Solutions SAP avec Machine Learning (SAP Leonardo ML)	Analyse basée sur des modèles de Machine Learning	Détection d'anomalies Analyse prédictive Intégration ERP native	Coût élevé Dépendance au cloud Personnalisation limitée
Approches hybrides (outils + intervention humaine)	Combinaison de monitoring automatique et analyse manuelle	Flexibilité Adaptation aux besoins spécifiques Exploitation de l'expertise humaine	Dépendance aux consultants Charge opérationnelle élevée Risque d'erreur humaine

Synthèse

L'analyse des solutions existantes montre que, malgré la disponibilité d'outils performants, la surveillance des systèmes SAP reste largement dépendante de configurations spécifiques, de règles statiques et de l'intervention humaine.

Les capacités d'analyse avancée, notamment en termes de compréhension contextuelle des événements et de détection intelligente des anomalies, restent limitées ou partiellement exploitées dans les solutions actuelles.

Afin de remédier aux limites constatées dans le système actuel, un système de surveillance intelligent des environnements SAP est proposé. Cette solution a pour objectif d'automatiser la détection des anomalies, de fournir des alertes enrichies en contexte et de centraliser l'accès à la documentation SAP.

- **Collecte et traitement de la documentation** : La solution collecte automatiquement la documentation SAP depuis le portail SAP Help ainsi que les livres techniques, en préservant leur structure et leur contenu. Les données collectées sont ensuite nettoyées, organisées et enrichies avec des informations contextuelles pour faciliter leur exploitation ultérieure.
- **Collecte et traitement de la documentation** : La solution collecte automatiquement la documentation SAP depuis le portail SAP Help ainsi que les livres techniques, en préservant leur structure et leur contenu. Les données collectées sont ensuite nettoyées, organisées et enrichies avec des informations contextuelles pour faciliter leur exploitation ultérieure.
- **Base de connaissances centralisée** : L'ensemble de la documentation traitée est stocké dans une base de connaissances unifiée, permettant aux consultants d'interroger directement le système en langage naturel pour retrouver une information pertinente, sans avoir à naviguer manuellement entre plusieurs sources.
- **Recherche et génération de réponses** : Lorsqu'un consultant pose une question, le système identifie les documents les plus pertinents dans la base de connaissances et génère automatiquement une réponse argumentée et sourcée, adaptée au contexte de la requête.
- **Prévention des erreurs** : Des mécanismes de validation sont intégrés pour s'assurer que les réponses générées sont bien fondées sur la documentation disponible et non sur des informations incorrectes.
- **Interface et déploiement** : La solution est accessible via une interface web intuitive comprenant un chatbot de support, un tableau de bord de surveillance en temps réel et un panneau d'administration. Elle est également connectée à Microsoft Teams afin de notifier automatiquement les équipes lors de la survenue d'incidents critiques.

1.3 Méthodologie de développement

1.3.1 Présentation des méthodologies candidates

CRISP-DM

CRISP-DM (*Cross-Industry Standard Process for Data Mining*) est une méthodologie éprouvée par l'industrie pour guider les projets de fouille de données. Son cycle de vie se compose de six phases interdépendantes (voir Figure ??) :



FIGURE 1.4 – Cycle de vie du framework CRISP-DM

1. **Compréhension métier (*Business Understanding*)** : Définir les objectifs du projet et traduire les objectifs métier en problèmes de fouille de données.
2. **Compréhension des données (*Data Understanding*)** : Collecter les données initiales, évaluer leur qualité et découvrir des premières perspectives.
3. **Préparation des données (*Data Preparation*)** : Nettoyer, transformer et mettre en forme les données pour les besoins de la modélisation.
4. **Modélisation (*Modeling*)** : Sélectionner et appliquer des techniques de modélisation avec des paramètres optimisés.
5. **Évaluation (*Evaluation*)** : Évaluer les résultats du modèle par rapport aux objectifs métier et aux critères de succès.
6. **Déploiement (*Deployment*)** : Mettre en production les résultats et établir une stratégie de surveillance continue.

Avantages de CRISP-DM

- **Orienté métier** : Démarre par la compréhension métier, en parfait alignement avec les besoins d'entreprise tels que l'interprétation des anomalies SAP et l'analyse d'impact.
- **Workflow itératif** : Encourage les retours continus et le raffinement du modèle, utile pour améliorer la précision et la pertinence des alertes.

- **Neutre technologiquement** : N'impose pas de contraintes d'outillage, bien adapté à une intégration flexible avec des stacks modernes.
- **Largement adopté** : Éprouvé par l'industrie et soutenu par une documentation et des outils abondants.
- **Accent sur l'évaluation** : Inclut des phases dédiées à l'évaluation de la performance technique et de l'adéquation métier, essentielles pour les applications de surveillance SAP.

Limites de CRISP-DM

- **Absence de MLOps intégré** : Ne traite pas nativement les pratiques de déploiement modernes (CI/CD, versionnage, surveillance).

KDD – Knowledge Discovery in Databases

Le processus KDD (*Knowledge Discovery in Databases*), introduit par Fayyad et al. en 1996, est l'une des premières méthodologies formelles pour extraire des connaissances actionnables de larges volumes de données. Il met l'accent sur le cycle de vie complet, de la préparation des données jusqu'à l'interprétation des connaissances.




FIGURE 1.5 – Étapes du processus KDD

Avantages

- Fort accent sur la validité, la nouveauté et l'utilité des connaissances.
- Promeut un pipeline d'analyse de données complet et itératif.

Inconvénients

- Guidance limitée sur le déploiement ou l'opérationnalisation.
- Moins d'accent sur les pratiques agiles ou les principes d'ingénierie logicielle.

TDSP – Team Data Science Process

Le TDSP (*Team Data Science Process*) est un framework développé par Microsoft pour guider les projets de data science. Son cycle de vie comprend cinq étapes itératives, similaires à celles de CRISP-DM (voir Figure ??).




FIGURE 1.6 – Cycle de vie de la méthodologie Microsoft TDSP

1. **Compréhension métier** : Définir les objectifs et identifier les sources de données.
2. **Acquisition et compréhension des données** : Ingérer les données et déterminer si elles peuvent répondre à la question posée.
3. **Modélisation** : Ingénierie des fonctionnalités et entraînement des modèles.
4. **Déploiement** : Mise en production dans un environnement opérationnel.

Avantages

- **Agile** : Insiste sur les livrables incrémentaux.
- **Familier** : Backlog produit, user stories, versionnage Git et sprint planning familiers aux équipes habituées aux pratiques logicielles courantes.
- **Natif data science** : Reconnaît les différences entre data science et ingénierie logicielle.
- **Flexible** : Peut être implémenté seul ou combiné avec d'autres approches.

Inconvénients

- **Sprints fixes** : De nombreux data scientists peinent avec les sprints de durée fixe imposés par TDSP.
- **Quelques incohérences** : La documentation Microsoft n'est pas toujours parfaitement cohérente.

1.3.2 Comparaison des méthodologies

TABLE 1.2 – Comparaison des méthodologies CRISP-DM, TDSP et KDD

Aspect	CRISP-DM	TDSP	KDD
Objectif principal	Processus structuré et itératif pour la fouille de données orientée métier	Cycle de vie agile pour projets ML scalables	Extraction de patterns et connaissances depuis des données brutes
Intégration métier	Forte : la compréhension métier est le point de départ	Forte : phase d'alignement intégré	Limitée : orientée données et patterns
Préparation des données	Extensive et itérative	Forte, souvent automatisée	Phase centrale
Support à la modélisation	Sélection et ajustement de modèles inclus	Fort avec suivi de performance	Présent mais moins structuré
Support au déploiement	Modéré : inclus mais peu prescriptif	Fort : accent sur la production et DevOps	Minimal
Interprétabilité	Soulignée lors de l'évaluation	Modérée : axée sur la reproductibilité	Haute : les patterns doivent être compréhensibles
Meilleur cas d'usage	Fouille de données avec contexte métier fort	Flux ML collaboratifs et itératifs	Découverte de connaissances dans des données brutes non étiquetées

1.3.3 Méthodologie retenue : CRISP-DM

CRISP-DM a été adoptée comme méthodologie principale de ce projet en raison de son alignement métier, de sa neutralité technologique et de son accent sur l'amélioration itérative — une exigence clé pour la construction d'un assistant de surveillance SAP utilisable et adaptable.

Conclusion

Ce chapitre a mis en évidence l'importance stratégique du développement d'un système de détection d'anomalies SAP répondant aux lacunes critiques des approches de surveillance actuelles. Grâce à la méthodologie CRISP-DM, le projet vise à transformer la surveillance SAP réactive en une détection d'anomalies proactive et contextualisée. La solution proposée, basée sur une architecture hybride RAG enrichie par des graphes de connaissances, constitue une réponse innovante aux limites des outils existants, tout en s'appuyant sur des technologies open source accessibles et performantes.

Chapitre 2

Planification et spécification des besoins

Introduction

1. Visions et objectifs du système futur
2. Spécification des besoins
3. Diagramme de cas d'utilisation général
4. Gestion de projet avec la méthode CRISP-DM
5. Diagramme de Gantt

Conclusion

Introduction

Ce chapitre présente le futur système de l'application en mettant en évidence ses principaux objectifs ainsi que la spécification des besoins. Il distingue les exigences fonctionnelles des exigences non fonctionnelles nécessaires au bon fonctionnement du système.

Nous présenterons également une vue d'ensemble des interactions entre les utilisateurs et le système, accompagnée de prototypes d'interfaces illustrant les principales fonctionnalités proposées.

Enfin, nous aborderons l'adoption de la méthodologie CRISP-DM afin d'organiser et de structurer le projet en nous appuyant sur les différentes étapes de ce processus.

2.1 Vision et objectifs du système futur

Dans le cadre de l'optimisation et de la modernisation de l'exploitation des systèmes SAP, le projet vise à développer un assistant intelligent capable d'analyser et d'exploiter de manière efficace les données issues des différentes transactions et opérations. Les principaux objectifs du système futur sont les suivants :

- **Centraliser et organiser les données SAP** provenant des différents modules, afin de disposer d'une source unique et fiable d'informations.
- **Analyser et interpréter les données** grâce à des techniques d'intelligence artificielle et d'analyse avancée, transformant les informations brutes en indicateurs et rapports exploitables.
- **Détecter rapidement les anomalies et incidents** en utilisant l'IA pour identifier les comportements inhabituels ou les erreurs récurrentes dans le système.
- **Intégrer la documentation SAP** pour fournir aux utilisateurs des recommandations, des explications et des solutions adaptées aux problèmes rencontrés.
- **Offrir une interface interactive** sous forme d'assistant conversationnel permettant aux utilisateurs de poser des questions, d'obtenir des analyses et de recevoir des conseils personnalisés.
- **Assurer une accessibilité via une application web** intuitive, permettant de visualiser les analyses, exploiter les données collectées et interagir avec l'assistant de manière ergonomique.

Ainsi, ce système contribuera à améliorer la compréhension et la gestion des données SAP, à faciliter l'analyse des anomalies, et à offrir un outil intelligent d'aide à la décision pour les utilisateurs.

2.2 Spécification des besoins

L'analyse des besoins a pour objectif de comprendre les attentes des utilisateurs et à définir le contexte métier dans lequel s'inscrit le système à développer. Elle permet de décrire les fonctionnalités que le système prendra en charge, ses interactions avec les différents intervenants, ainsi que les règles qui encadrent ces interactions.

2.2.1 Identification des acteurs

Pour déterminer les besoins fonctionnels et non fonctionnels, nous débutons par l'identification des acteurs impliqués dans le système, en précisant le rôle spécifique de chacun. Ainsi, nous identifions trois rôles distincts qui interagissent avec le système :

2.2.2 Besoins fonctionnels

Les besoins fonctionnels définissent les différentes fonctionnalités que le système doit fournir afin de permettre aux utilisateurs d'exploiter et d'analyser les données provenant du système SAP à travers un assistant intelligent basé sur l'intelligence artificielle.

Le système comporte principalement deux types d'acteurs : l'**Administrateur SAP** et l'**Utilisateur SAP**.

Administrateur SAP

L'administrateur assure un rôle de supervision du système. Ses principales fonctionnalités sont les suivantes :

- S'authentifier à l'application.
- Consulter les journaux d'activité du système SAP.
- Accéder aux graphiques et analyses générés par l'assistant intelligent.
- Configurer les paramètres du système et les règles d'alertes.
- Consulter l'historique global des conversations effectuées avec le chatbot.

Utilisateur SAP

L'utilisateur SAP constitue l'acteur principal de l'application. Il peut exploiter les fonctionnalités suivantes :

- S'authentifier à l'application.
- Interagir avec l'assistant intelligent à travers une interface conversationnelle.
- Poser des questions en langage naturel concernant les données issues du système SAP.

- Consulter les alertes associées aux transactions SAP (T-Code).
- Accéder aux journaux des transactions SAP.
- Visualiser les graphiques et analyses générés par le système.
- Consulter l'historique des interactions avec le chatbot.

2.2.3 Besoins Non Fonctionnels

Les besoins non fonctionnels définissent les contraintes qualité du système indépendamment des fonctionnalités métier. Pour un système RAG déployé en environnement SAP BASIS de production, ces exigences sont critiques car une réponse incorrecte sur une procédure de configuration peut provoquer des incidents système graves.

Performance

Le pipeline complet (retrieval + génération) doit retourner une réponse en moins de **5 secondes** pour 95% des requêtes. Ce seuil justifie le choix de l'index HNSW (recherche en $O(\log n)$) et le déploiement local du LLM via Ollama pour éliminer toute latence réseau.

Fiabilité

Le taux d'hallucination doit rester inférieur à **5%**, garanti par la validation NLI à chaque réponse générée. Si aucun chunk pertinent n'est trouvé (score similarité < 0.5), le système retourne explicitement une absence de réponse plutôt que d'inventer une information.

Confidentialité

L'intégralité du pipeline tourne en local — LLM via Ollama, base vectorielle via pgvector. Aucune donnée SAP (configurations, credentials, topologie réseau) n'est transmise à des APIs cloud externes. C'est un prérequis non négociable pour les environnements d'entreprise SAP.

Scalabilité

L'index HNSW supporte l'insertion incrémentale sans reconstruction, ce qui permet d'ajouter de nouvelles SAP Notes ou de nouveaux modules sans réindexer l'intégralité du corpus.

2.2.4 Synthèse

TABLE 2.1 – Synthèse des besoins non fonctionnels

Catégorie	Seuil cible	Mécanisme
Temps de réponse	$\leq 5s$ (p95)	HNSW + Ollama local
Taux hallucination	$\leq 5\%$	Validation NLI
Recall@5	≥ 0.75	BM25 + vecteur hybride
Confidentialité données	100% local	Ollama on-premise
Insertion incrémentale	Sans rebuild	Index HNSW
Maintenabilité	Pipeline rejouable	Git + scripts versionnés

2.3 Diagramme de cas d'utilisation général

Dans cette section, les exigences fonctionnelles du système sont représentées à l'aide d'un diagramme de cas d'utilisation conforme au langage de modélisation UML. Ce diagramme (voir figure ??) met en évidence les différents acteurs du système ainsi que les interactions possibles entre ces acteurs et les fonctionnalités offertes par l'application. Il permet ainsi de fournir une vision globale du comportement du système et des services qu'il propose aux utilisateurs.




FIGURE 2.1 – Diagramme de cas d'utilisation général du système

Chapitre 3

Compréhension métier

Introduction

Ce chapitre présente le contexte métier et les objectifs du projet de détection d'anomalies dans le cadre de la méthodologie CRISP-DM. Il met en évidence l'importance d'aligner les efforts techniques sur les objectifs métier, afin que la solution développée réponde aux défis réels auxquels sont confrontées les équipes SAP.

3.1 État de l'art

3.1.1 Qu'est-ce qu'un ERP ?

Un système ERP (*Enterprise Resource Planning*) est un logiciel qui intègre et gère les principaux processus métier d'une organisation : finances, ressources humaines, fabrication, chaîne d'approvisionnement, ventes et achats. Il fournit une source unique de vérité, élimine la duplication des données et améliore l'efficacité opérationnelle. Les solutions ERP permettent aux entreprises d'obtenir une visibilité en temps réel sur leurs opérations, d'automatiser les processus et de prendre des décisions basées sur les données.

SAP (*Systems, Applications and Products in Data Processing*) est l'un des principaux fournisseurs de logiciels ERP. Sa suite logicielle couvre de nombreux domaines fonctionnels. Parmi ses modules les plus utilisés :

- **SAP EWM (*Extended Warehouse Management*)** : Module spécialisé dans l'optimisation des entrepôts et la gestion des stocks. Il aide les entreprises à gérer efficacement leurs opérations d'entreposage et à garantir la disponibilité des produits au bon moment.
- **SAP ECC (*Enterprise Central Component*)** : Module central de l'ERP SAP. Il intègre les finances, les ventes, les achats, la fabrication et les ressources humaines

au sein d'une plateforme unifiée.

- **SAP Solution Manager (SOLMAN)** : Outil central de gestion et de surveillance fourni par SAP. Il couvre la gestion du cycle de vie des applications, la gestion de projets, la gestion des services IT et le suivi des processus métier.

3.1.2 Le consultant SAP BASIS

Le consultant SAP BASIS est responsable de l'infrastructure technique de l'environnement SAP : installations, mises à jour et application des correctifs. Il assure la résolution des problèmes de connectivité, les ajustements de composants et l'assistance aux systèmes externes et aux bases de données. Ses principales responsabilités comprennent :

1. Administration des systèmes
2. Surveillance et optimisation des performances
3. Administration de la sécurité
4. Administration des bases de données
5. Résolution des incidents techniques
6. Sauvegarde et récupération des données
7. Gestion des intégrations et des interfaces
8. Mises à jour et migrations des systèmes
9. Documentation et formation

3.1.3 Les codes de transaction SAP (T-codes)

Dans SAP, les codes de transaction (T-codes) sont des commandes alphanumériques courtes permettant d'accéder rapidement à des fonctions spécifiques, des rapports ou des diagnostics système. Ils servent de points d'entrée dans les modules fonctionnels de SAP, permettant aux utilisateurs de contourner les menus profonds et d'exécuter directement des tâches telles que la surveillance des jobs, la gestion des files d'attente ou l'analyse des performances.

Chaque T-code correspond à une fonction ou un programme backend — généralement implémenté en ABAP — qui effectue un ensemble défini d'opérations. Lors de l'exécution d'un T-code, SAP vérifie les autorisations de l'utilisateur, exécute la logique associée et présente une interface interactive.

Dans le cadre de ce projet, un ensemble de T-codes à haute criticité a été sélectionné pour assurer une couverture complète du comportement des systèmes SAP :


- **ST22** – Analyse des erreurs d'exécution ABAP (*short dumps*).

- DB02 – Surveillance des statistiques de base de données (croissance, espace table, index manquants).
- SM37 – Surveillance des jobs en arrière-plan.
- SP01 – Vérification des requêtes d'impression et de leurs statuts.
- SM66 – Vue globale des processus de travail actifs.
- SM58 – Analyse des erreurs RFC transactionnelles (traitement asynchrone).
- SMQ1, SMQ2 – Surveillance des files d'attente entrantes et sortantes (qRFC/tRFC).
- SM12, SM13 – Révision des entrées verrouillées et des enregistrements de mise à jour.
- ST03N – Analyse des statistiques de charge de travail et de performance.
- SOST – Surveillance des messages SAPconnect (e-mails, fax, etc.).
- ST13 – Outils BASIS pour les diagnostics approfondis et les journaux.

Ces T-codes ont été sélectionnés en raison de leur criticité pour les opérations en temps réel, de leur pertinence pour les équipes BASIS et de leur fréquence d'utilisation lors de la résolution des incidents. En surveillant en continu ces transactions et en interprétant leurs sorties par le biais d'un raisonnement assisté par IA, le système permet une détection précoce des anomalies et soutient une analyse plus rapide des causes profondes.

SM37 — Job Overview

SM37 surveille les *jobs batch* — ce sont des tâches automatiques qui tournent en arrière-plan (traitements de données, interfaces, rapports). L'administrateur vérifie qu'aucun job n'est en erreur ou bloqué.



Job	Job Created	Status	Start date	Start time	Duration(sec.)	Delay (sec.)
/BDL/TASK_PROCESSOR	ITELLIUSER	Released	24.04.2026	00:27:36	0	0
/BDL/TASK_PROCESSOR	ITELLIUSER	Finished	24.04.2026	01:27:36	0	15
/BDL/TASK_PROCESSOR	ITELLIUSER	Finished	24.04.2026	02:27:36	0	15
/BDL/TASK_PROCESSOR	ITELLIUSER	Finished	24.04.2026	03:27:36	0	15
/BDL/TASK_PROCESSOR	ITELLIUSER	Finished	24.04.2026	04:27:36	0	15
/BDL/TASK_PROCESSOR	ITELLIUSER	Finished	24.04.2026	05:27:36	0	15
/BDL/TASK_PROCESSOR	ITELLIUSER	Finished	24.04.2026	06:27:36	0	15
/BDL/TASK_PROCESSOR	ITELLIUSER	Finished	24.04.2026	07:27:30	0	9
/BDL/TASK_PROCESSOR	ITELLIUSER	Finished	24.04.2026	08:27:29	0	8
/BDL/TASK_PROCESSOR	ITELLIUSER	Finished	24.04.2026	09:27:21	0	0
/SDF/MON_SCHEDULER	ABEELMOU	Finished	24.04.2026	00:00:01	3	1
/SDF/MON_WATCHDOG	ABEELMOU	Released			0	0
/SDF/MON_WATCHDOG	ABEELMOU	Finished	24.04.2026	00:50:25	0	11
/SDF/MON_WATCHDOG	ABEELMOU	Finished	24.04.2026	01:50:25	0	11
/SDF/MON_WATCHDOG	ABEELMOU	Finished	24.04.2026	02:50:25	0	11
/SDF/MON_WATCHDOG	ABEELMOU	Finished	24.04.2026	03:50:25	1	11
/SDF/MON_WATCHDOG	ABEELMOU	Finished	24.04.2026	04:50:25	0	11
/SDF/MON_WATCHDOG	ABEELMOU	Finished	24.04.2026	05:50:25	0	11
/SDF/MON_WATCHDOG	ABEELMOU	Finished	24.04.2026	06:50:25	0	11
/SDF/MON_WATCHDOG	ABEELMOU	Finished	24.04.2026	07:50:25	0	11
/SDF/MON_WATCHDOG	ABEELMOU	Finished	24.04.2026	08:50:14	0	0
0000000094636939	NFPA-211010	Finished	24.04.2026	06:02:05	1	0
0000000094636940	NFPA-211010	Finished	24.04.2026	06:02:06	0	0
0000000094636941	NFPA-211010	Finished	24.04.2026	06:02:05	1	0
0000000094636942	NFPA-211010	Finished	24.04.2026	06:02:05	1	0
0000000094636943	NFPA-211010	Finished	24.04.2026	06:02:09	3	0
0000000094636944	NFPA-211010	Finished	24.04.2026	06:02:09	1	0
0000000094636945	NFPA-211010	Finished	24.04.2026	06:02:09	1	0
0000000094636946	NFPA-211010	Finished	24.04.2026	06:02:09	1	0

FIGURE 3.1 – SM37 — Vue d'ensemble des jobs batch

La figure SM37 présente l’interface du T-code **SM37**, qui affiche la liste des jobs planifiés avec leur statut (*Finished*, *Released*, *Active*), leur date et heure de démarrage, leur durée d’exécution ainsi que le délai éventuel. Cette vue permet à l’administrateur BASIS d’identifier en un coup d’œil tout job bloqué, annulé ou présentant un délai anormal, et d’intervenir rapidement avant que cela n’impacte les processus métier.

DB02 — Space Overview

DB02 surveille la base de données — l’administrateur contrôle l’espace disque disponible pour éviter que la base de données sature, ce qui provoquerait un arrêt complet du système.




FIGURE 3.2 – DB02 — Vue d’ensemble de l’espace base de données

La figure db02 illustre le T-code DB02, qui fournit une vue synthétique de l’état de la base de données Oracle. On y retrouve le taux de remplissage global, la taille totale et l’espace libre, ainsi que le détail par tablespace et par segment (tables, index, autres). Un taux d’utilisation élevé — comme les 87% visibles ici — constitue un signal d’alerte critique nécessitant une action immédiate d’extension ou de purge pour prévenir toute saturation du système.

ST22 — Runtime Errors

ST22 liste les erreurs critiques ABAP — l’administrateur analyse les *dumps* pour identifier les programmes qui plantent et corriger les problèmes avant qu’ils n’impactent les utilisateurs.

Current Date Time	App. Server	User Name	CL - KeName of runtime error	Exception	Appl. component
24.04.2026 09:19:16	ECC-P11-00_P11...CONFAUTO		620 C TSV_TNEW_PAGE_ALLOC_FAILED		
24.04.2026 09:18:50	ECC-P11-00_P11...CONFAUTO		620 C TSV_TNEW_PAGE_ALLOC_FAILED		
24.04.2026 09:13:51	ECC-P11-00_P11...CONFAUTO		620 C TSV_TNEW_PAGE_ALLOC_FAILED		
24.04.2026 09:00:46	ECC-P11-01_P11...WF-BATCH		620 C SAPSQL_ARRAY_INSERT_DURREC	CX_SY_OPEN_SQL_DB	
24.04.2026 08:43:05	ECC-P11-00_P11...CONFAUTO		620 C TSV_TNEW_PAGE_ALLOC_FAILED		
24.04.2026 08:42:40	ECC-P11-00_P11...CONFAUTO		620 C TSV_TNEW_PAGE_ALLOC_FAILED		
24.04.2026 08:36:46	ECC-P11-00_P11...SM_PM1		000 C TABLE_ILLEGAL_STATEMENT		
24.04.2026 08:24:29	ECC-P11-00_P11...CONFAUTO		620 C TSV_TNEW_PAGE_ALLOC_FAILED		
24.04.2026 08:10:16	ECC-P11-00_P11...CONFAUTO		620 C TSV_TNEW_PAGE_ALLOC_FAILED		
24.04.2026 07:57:02	ECC-P11-00_P11...CONFAUTO		620 C TSV_TNEW_PAGE_ALLOC_FAILED		
24.04.2026 07:56:35	ECC-P11-00_P11...CONFAUTO		620 C TSV_TNEW_PAGE_ALLOC_FAILED		
24.04.2026 07:43:34	ECC-P11-00_P11...CONFAUTO		620 C TSV_TNEW_PAGE_ALLOC_FAILED		
24.04.2026 07:36:39	ECC-P11-00_P11...SM_PM1		000 C TABLE_ILLEGAL_STATEMENT		
24.04.2026 06:55:42	ECC-P11-00_P11...WF-BATCH		620 C SAPSQL_ARRAY_INSERT_DURREC	CX_SY_OPEN_SQL_DB	
24.04.2026 06:36:43	ECC-P11-00_P11...SM_PM1		000 C TABLE_ILLEGAL_STATEMENT		
24.04.2026 05:36:39	ECC-P11-00_P11...SM_PM1		000 C TABLE_ILLEGAL_STATEMENT		
24.04.2026 05:02:16	ECC-P11-00_P11...WF-BATCH		620 C TSV_TNEW_PAGE_ALLOC_FAILED		
24.04.2026 05:01:23	ECC-P11-00_P11...WF-BATCH		620 C TSV_TNEW_PAGE_ALLOC_FAILED		
24.04.2026 04:36:46	ECC-P11-00_P11...SM_PM1		000 C TABLE_ILLEGAL_STATEMENT		
24.04.2026 03:36:41	ECC-P11-00_P11...SM_PM1		000 C TABLE_ILLEGAL_STATEMENT		
24.04.2026 02:36:44	ECC-P11-00_P11...SM_PM1		000 C TABLE_ILLEGAL_STATEMENT		
24.04.2026 01:36:47	ECC-P11-00_P11...SM_PM1		000 C TABLE_ILLEGAL_STATEMENT		
24.04.2026 00:36:43	ECC-P11-00_P11...SM_PM1		000 C TABLE_ILLEGAL_STATEMENT		
23.04.2026 23:36:42	ECC-P11-00_P11...SM_PM1		000 C TABLE_ILLEGAL_STATEMENT		
23.04.2026 23:00:27	ECC-P11-01_P11...WF-BATCH		000 C DDIC_TYPES_INCONSISTENT		
23.04.2026 23:00:24	ECC-P11-01_P11...WF-BATCH		000 C DDIC_TYPES_INCONSISTENT		
23.04.2026 23:00:22	ECC-P11-01_P11...WF-BATCH		000 C DDIC_TYPES_INCONSISTENT		
23.04.2026 23:00:19	ECC-P11-01_P11...WF-BATCH		000 C DDIC_TYPES_INCONSISTENT		
23.04.2026 22:36:48	ECC-P11-00_P11...SM_PM1		000 C TABLE_ILLEGAL_STATEMENT		
23.04.2026 21:36:47	ECC-P11-00_P11...SM_PM1		000 C TABLE_ILLEGAL_STATEMENT		
23.04.2026 20:36:58	ECC-P11-00_P11...SM_PM1		000 C TABLE_ILLEGAL_STATEMENT		
23.04.2026 20:00:54	ECC-P11-00_P11...SM_PM1		000 C TABLE_ILLEGAL_STATEMENT		

FIGURE 3.3 – ST22 — Liste des erreurs d'exécution ABAP

La figure ST22 présente l'interface du T-code ST22, qui recense l'ensemble des *short dumps* ABAP survenus sur le système. Chaque entrée indique la date, l'heure, le serveur applicatif, l'utilisateur concerné et le nom de l'erreur. Les erreurs récurrentes telles que `TSV_TNEW_PAGE_ALLOC_FAILED` (manque de mémoire) ou `TABLE_ILLEGAL_STATEMENT` (instruction SQL non autorisée) sont des indicateurs d'anomalies systémiques qui doivent être analysées et résolues en priorité par l'équipe BASIS.

3.1.4 Les Fondements Technologiques de l'IA Générative

L'intelligence artificielle générative s'appuie sur une série de composants technologiques complémentaires qui, lorsqu'ils sont assemblés, permettent la création de systèmes capables d'interpréter, de raisonner et de produire du contenu à partir de données complexes. Ce rapport se concentre sur deux éléments essentiels : les modèles de langage de grande taille (LLMs), qui assurent la compréhension et la génération, et l'architecture RAG (*Retrieval-Augmented Generation*), qui améliore ces modèles en leur offrant une base de savoir actualisée et vérifiable.

3.1.5 Architecture de l'IA RAG

Un grand modèle de langage (LLM) détient une compréhension générale acquise lors de son entraînement, mais il n'a pas d'accès direct à vos documents internes, à vos bases de données confidentielles ou aux informations les plus récentes. L'architecture RAG (*Retrieval-Augmented Generation*) pallie cette lacune : avant de générer une réponse, le système découpe d'abord les documents sources en fragments appelés *chunks* — de

courts passages de quelques phrases ou paragraphes —, puis transforme chacun d’eux en un *embedding*, c’est-à-dire un vecteur numérique qui encode le sens du texte plutôt que ses mots exacts. Ces vecteurs sont stockés dans une base de données vectorielle, qui permet de retrouver en quelques millisecondes les chunks sémantiquement les plus proches d’une question donnée, grâce à une mesure de similarité cosinus. On peut percevoir le RAG comme un assistant disposant de sa propre bibliothèque : au lieu de répondre directement de mémoire, il consulte d’abord les bonnes références, extrait les passages essentiels, les injecte dans son contexte, puis construit une réponse ancrée sur des faits vérifiables et traçables.




FIGURE 3.4 – Pipeline RAG : indexation, vectorisation, récupération et génération

3.1.6 Large Language Models (LLMs)

Un LLM (*Large Language Model*) est un type de modèle d’intelligence artificielle qui a été formé sur d’énormes volumes de textes — tels que livres, articles, sites internet, code — dans le but de comprendre les structures, les significations et les connexions entre les mots d’une langue. En pratique, il anticipe le terme (ou jeton) le plus susceptible de suivre un certain texte et c’est en répétant ce processus des milliers de fois qu’il produit des réponses cohérentes, rédige des documents, fait des traductions, résume ou répond à des interrogations. Plus le modèle est vaste (comportant des milliards de paramètres), plus il a la capacité de saisir les subtilités complexes du langage. Des exemples de LLM accessibles au public comprennent ChatGPT, Claude et Gemini.

Conclusion

Ce chapitre souligne l’importance stratégique du développement d’un système de détection d’anomalies adapté aux transactions SAP dans le cadre de la méthodologie CRISP-DM. En alignant les capacités techniques sur les objectifs métier, ce projet vise à améliorer l’efficacité opérationnelle des équipes BASIS, à optimiser les processus de prise de décision et à réduire le temps moyen de résolution des incidents.

Chapitre 4

Compréhension et Acquisition des Données

4.1 Introduction

Le chapitre d'acquisition et de compréhension des données est essentiel pour établir une base solide pour le système de détection d'anomalies développé pour les transactions SAP. Ce chapitre détaille la collecte, le traitement et l'analyse systématiques des données nécessaires pour comprendre le contexte métier, définir les conditions d'alerte et identifier les schémas de transactions anormales. Il met en évidence l'importance des documents de base de connaissances (KB), élaborés en fonction des besoins métier, qui guident les processus de surveillance et de génération d'alertes. Dans le cadre de ce projet, trois sources de données hétérogènes ont été identifiées et exploitées :

- Le **portail SAP Help Portal** — documentation officielle SAP accessible via scraping web
- Les **livres techniques SAP** — 298 ouvrages de formation au format PDF couvrant les modules BASIS, ABAP, Fiori et S/4HANA
- Les **logs de transactions SAP** — données temps réel extraites depuis les transactions SM37, ST22 et SP01

4.2 Sources

4.2.1 SAP Help Portal

Description et structure

Le SAP Help Portal (help.sap.com) constitue la source de documentation officielle SAP. Il expose une structure hiérarchique profonde de pages HTML organisées par pro-

duit, version et module. Chaque page contient du contenu textuel structuré (procédures, paramètres, notes techniques) ainsi que des métadonnées de navigation (breadcrumbs, liens parent-enfant).

Caractéristiques du SAP Help Portal

- **Volume** : environ 50,000 pages indexées par le sitemap
- **Structure** : hiérarchie à 4-6 niveaux de profondeur
- **Langue** : principalement anglais, avec contenu français et allemand
- **Versions** : SAP NetWeaver 7.x, S/4HANA, Fiori Launchpad
- **Types de contenu** : procédures pas-à-pas, références API, notes de configuration, paramètres de transactions

Architecture de scraping

La figure ?? présente l'architecture complète du pipeline de web scraping développé pour extraire la documentation du SAP Help Portal.




FIGURE 4.1 – Architecture et flux du web scraping SAP Help Portal

Gestion des structures imbriquées

Le SAP Help Portal présente des structures documentaires imbriquées à plusieurs niveaux. Notre framework de scraping adresse ce défi par quatre mécanismes complémentaires :

1. **Breadcrumb Tracking** — maintien du chemin de navigation complet pour préserver la localisation de chaque document dans la hiérarchie globale. Exemple : ["SAP Fiori Launchpad", "Configuring Roles", "Tile Catalogs"]
2. **Relations Parent-Enfant** — capture explicite des liens `parent_id` / `doc_id` entre documents principaux et sous-documents, permettant la reconstruction de la hiérarchie complète

3. **Cross-Reference Mapping** — identification et préservation des liens entre documents connexes dans différentes sections (liens hypertexte inter-modules)
4. **Context Inheritance** — les documents imbriqués héritent du contexte pertinent de leurs parents (version SAP, module, composants mentionnés)

4.2.2 Livres Techniques SAP (PDFs)

Description du corpus

Le corpus de livres techniques SAP comprend 298 ouvrages de formation officielle couvrant l'ensemble des modules SAP. Ces documents, au format PDF, présentent une structure pédagogique standardisée (unités, leçons, exercices, évaluations) et constituent une source de connaissance procédurale dense.

Caractéristiques du corpus PDF

- **Volume** : 298 ouvrages, environ 45,000 pages
- **Format** : PDF avec structure hiérarchique (chapitres, sections, sous-sections)
- **Contenu** : procédures de configuration, schémas d'architecture, tableaux de paramètres, exercices pratiques
- **Modules couverts** : BASIS, ABAP, Fiori, S/4HANA, MM, SD, FI, CO, HR, PM
- **Défis techniques** : encodage CID dans certains PDFs, espaces manquants dans les polices personnalisées, tables des matières indexées comme contenu

Pipeline d'ingestion des données

La figure ?? présente le pipeline complet d'ingestion des données depuis les sources brutes jusqu'à l'indexation dans pgvector.




FIGURE 4.2 – Pipeline complet d’ingestion des données SAP

Défis techniques et solutions

Trois problèmes majeurs ont été identifiés et résolus durant la phase d’acquisition :

Encodage CID dans les PDFs. Certains livres SAP utilisent des polices de type CIDFont sans table de correspondance Unicode. L’extracteur produit alors des séquences (cid:127) illisibles. La solution appliquée combine une détection par ratio de contamination (seuil 2%) et une conversion des codes CID fréquents vers leurs équivalents Unicode ((cid:127) → •).

Doublons inter-sources. Le portail SAP Help et les livres techniques partagent

parfois les mêmes procédures de configuration. 7,578 chunks dupliqués ont été identifiés par fingerprint MD5 sur les 300 premiers caractères normalisés et supprimés, en conservant le chunk avec les métadonnées les plus riches.

Pages QCM de formation. Les livres techniques SAP incluent des pages d'évaluation (quiz XTrue/XFalse) sans valeur documentaire pour le RAG. 5,618 chunks de ce type ont été filtrés par détection de patterns (XTrue, XFalse, `determine whether`).

4.2.3 Logs de Transactions SAP

Transactions surveillées

Le système surveille en temps réel trois transactions SAP BASIS critiques pour la santé de l'environnement :

Transactions SAP Monitorées

- **SM37** — Moniteur de jobs batch : suivi des travaux planifiés, détection des jobs en erreur ou bloqués
- **ST22** — Analyseur de dumps ABAP : capture et analyse des exceptions runtime du système ABAP
- **SP01** — Gestionnaire de spool : surveillance des impressions et des sorties système

Structure des données SM37

Le listing ?? présente la structure de données extraite depuis la transaction SM37 pour l'alimentation du pipeline RAG en temps réel.


```

1  # SM37 Transaction Data Structure
2  # Extracted via RFC/BAPI call to SAP system
3
4  sm37_record = {
5      # Identifiants
6      "job_name":      "RDDIMPDP",          # Nom du job batch
7      "job_id":        "14521234",         # ID unique SAP
8      "job_class":     "A",                # Priorite (A/B/C)
9
10     # Planification
11     "start_date":     "2024-01-15",       # Date de depart
12     "start_time":     "02:00:00",         # Heure de depart
13     "end_date":       "2024-01-15",       # Date de fin
14     "end_time":       "02:04:32",         # Heure de fin
15     "duration_sec":   272,                 # Duree en
                                     secondes
16
17     # Statut
18     "status":         "ABORTED",          # FINISHED/ABORTED
                                     /ACTIVE
19     "return_code":    4,                  # 0=OK, 4=Warning,
                                     8=Error
20
21     # Contexte systeme
22     "host":           "SAPAPP01",         # Serveur d'
                                     application
23     "client":         "100",              # Mandant SAP
24     "user":           "BATCHUSER",        # Utilisateur
                                     lanceur
25     "program":        "RDDIMPDP",         # Programme ABAP
                                     associe
26
27     # Correlation avec ST22
28     "dump_reference": "ST22-20240115-001", # Lien dump si
                                     ABORTED
29     "error_message":  "RAISE_EXCEPTION",  # Message d'erreur
                                     ABAP
30
31     # Metadonnees RAG
32     "source_type":    "transaction_log",
33     "transaction":    "SM37",
34     "extracted_at":   "2024-01-15T02:05:00Z",
35     "sap_version":    "S/4HANA 2023"
36 }

```

4.2.4 Pipeline d'extraction temps réel

L'extraction des données de transactions SAP repose sur deux mécanismes complémentaires :

1. **Appels RFC/BAPI** — connexion directe au système SAP via l'interface Remote Function Call. Les BAPIs standards `BAPI_XBP_JOB_SELECT` (SM37) et `BAPI_ABAP_DOCU_GET` (ST22) sont utilisés pour extraire les données sans modifier l'état du système
2. **Polling périodique** — interrogation toutes les 5 minutes pour les jobs actifs, toutes les 15 minutes pour l'historique des dernières 24 heures

Remarque

Les logs de transactions constituent la source de données **dynamique** du système, par opposition aux sources documentaires statiques (Help Portal et PDFs). Ils alimentent le contexte situationnel du RAG : lorsqu'un consultant interroge le système sur une erreur SM37, le contexte du job en erreur est automatiquement injecté dans le prompt de génération.

4.3 Analyse Statistique du Corpus Final

Le tableau ?? présente une synthèse statistique complète du corpus après l'ensemble des étapes de nettoyage et de filtrage.

TABLE 4.1 – Statistiques du corpus après normalisation et filtrage

Métrique	Valeur	Pourcentage	Remarque
<i>Volume brut</i>			
Pages SAP Help Portal scrappées	50,000	—	Sitemap complet
Livres PDF traités	298	—	Corpus complet
Figures extraites	47,219	—	Avant filtrage
<i>Après extraction</i>			
Chunks bruts totaux	155,721	100%	Avant nettoyage
dont SAP Help	21,084	13.5%	
dont livres techniques	87,418	56.1%	
dont figures	47,219	30.3%	
<i>Après corrections</i>			
Doublons supprimés	7,578	4.9%	Fingerprint MD5
QCM/Learning Assessment supprimés	5,618	3.6%	Bruit sémantique
Chunks CID corrompus filtrés	212	0.1%	WSMFB (97% CID)
Chunks dupliqués internes corrigés	3,808	2.4%	Truncation
<i>Corpus final</i>			
Total chunks normalisés	142,798	91.7%	
dont SAP Help	17,785	12.5%	0 CID, 0 TOC
dont livres techniques	83,990	58.8%	CID nettoyés
dont figures	46,368	32.5%	Caps. extraites
<i>Après chunking (indexés)</i>			
Chunks indexés total	105,331	73.8%	
Figures avec légende	39,014	37.0%	Indexables
SAP Help	30,433	28.9%	
Livres techniques	35,884	34.1%	
T-codes uniques extraits	2,794	—	Dont namespace
Longueur moyenne des chunks	175 tokens	—	Optimal bge-m3
Longueur maximale des chunks	600 tokens	—	≪ 8192 limite

4.4 Bilan de la Phase d'Acquisition

La phase d'acquisition et de compréhension des données a permis de constituer un corpus de **105,331 chunks indexables** à partir de trois sources hétérogènes, après application de huit corrections qualité motivées par des diagnostics empiriques sur les données réelles.

Les principaux enseignements de cette phase sont :

- La **diversité des sources** (documentation officielle, livres de formation, logs temps réel) est un avantage différenciateur majeur : le système peut répondre à la fois à des questions procédurales, conceptuelles et situationnelles
- La **rigueur du nettoyage** (8.3% de chunks supprimés ou corrigés) garantit que le retrieval ne sera pas pollué par du bruit sémantique (QCM, doublons, contenu illisible)
- L'**extraction des 2,794 T-codes** avec support des namespaces (/UI2/NWBC_CFG_CUST) constitue un avantage clé pour la recherche hybride BM25 : les identifiants SAP exacts sont préservés et indexés
- La **structure hiérarchique préservée** (breadcrumbs, parent_id, position) permettra d'enrichir le contexte de retrieval au Sprint 4 par injection du contexte parent